

# Huffman Codierung

Ein Algorithmus zur **verlustfreien** Datenkompression, der von **David A. Huffman** in **1952** entwickelt wurde. Sie erstellt kürzere Codes für häufiger auftretende Zeichen, während seltenere Zeichen längere Codes erhalten.

Ziel ist es, die Größe der zu speichernden oder zu übertragenden Daten zu reduzieren um somit die Übertragungsdauer zu verringern.

## 1.1 Funktionsweise

Jedem einzigartigen **Quellsymbol** wird ein festes **Codewort** zugewiesen. Die Codewörter variieren in der Länge. Um möglichst effizient die Codewörter zu gestalten, wird dem Quellsymbol, welches am häufigsten genutzt wird auch das kürzeste Codewort zugewiesen.

Dabei ist es wichtig, dass die Symbole **Präfixfrei**<sup>1</sup> sind. Dies ist nötig, um Symbole unterschiedlicher Länge eindeutig zu erkennen.

## 1.2 Aufbau eines Baumes

Um korrekte Codewörter zu finden, ist die gängigste Möglichkeit über einen  $k$ -nären Baum<sup>2</sup>. Folgend wird die vorgehensweise mittels eines binären Baums erläutert:

1. Für jedes Zeichen wird die Häufigkeit bestimmt
2. Aufbauen des Binärbaums<sup>3</sup>
  1. Die zwei kleinsten Knoten<sup>4</sup> finden (Falls es mehr als zwei Knoten gibt, wird der Knoten mit der geringsten Tiefe gewählt, ansonsten kann frei gewählt werden)
  2. Diese mit einem Knoten verknüpfen und die Häufigkeit der beiden Blätter addiert in den Knoten schreiben, bzw. speichern.
  3. Diese Schritte wiederholen, bis ein einzelner Binärbaum übrig ist.
3. Nun wird an jeden linken Ast eine Eins geschrieben und an jeden rechten eine 0<sup>5</sup>

<sup>1</sup> **Präfixfrei** heißt, kein Symbol darf mit einem anderen beginnen. So ist folgende Symbolgruppe Präfixfrei: {0, 100, 101, 11}, aber {10, 100, 101, 11} nicht.

<sup>2</sup> ein Baum dessen Knoten jeweils  $k$ -viele Blätter aufweisen

<sup>3</sup> Ein **Binärbaum** ist ein Baum, bei dem jeder Knoten **maximal zwei**

<sup>4</sup> Zu Beginn wird jeder Buchstabe als eigener Knoten betrachtet

<sup>5</sup> Es können natürlich beliebige Zeichen gewählt werden, 0 und 1 bieten sich bei der Speicherung auf einem Computer an, da sie ohne weitere Codierung direkt gespeichert werden können.

## 1.3 Beispiel: Mississippi




Abbildung 1.1: Beispiel der Huffmancodierung mittels eines Binärbaumes.